

# Doğrusal Sınıflandırıcılar ve Perceptron

# Perceptron Algoritması

- 1957 yılında Frank Rosenblatt tarafından Cornell Havacılık Laboratuvarında icat edilmiştir. (Cornell Aeronautical Laboratory)
- Doğrusal sınıflandırma algoritmasıdır.



Frank Rosenblatt

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

x sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıkışlar, etiketler yada hedefler

Düzlem (Plane) için  $d = 2$

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

 x sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

 Çıkışlar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıkışlar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Eğitim için örnek sayısı

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıkışlar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}, h(x) = 1$  ya da  $-1$

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıkışlar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

Uzayı (düzlemi) ikiye bölmektedir.



# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıkışlar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

- Eğitim hatası (Train Error) :  $\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[h(x^{(i)}) \neq y^{(i)}]$

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıkışlar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

- Eğitim hatası (Train Error) :  $\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[h(x^{(i)}) \neq y^{(i)}]$

1, eşit değil ise  
0, eşitse

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıkışlar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

- Eğitim hatası :  $\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket h(x^{(i)}) \neq y^{(i)} \rrbracket$

'n' burada hatamızı hesaplamak için kullanacağımız örnek sayısıdır.

1, eşit değil ise  
0, eşitse

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıktılar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

- Eğitim hatası :  $\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket \underbrace{h(x^{(i)}) \neq y^{(i)}}_{1, \text{ e\u015fit de\u011fil ise}} \rrbracket$

‘n’ burada hatamızı hesaplamak için kullanacağımız örnek sayıdır.

- Test hatası :  $\mathcal{E}(h)$

1, eşit değil ise  
0, eşitse

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıktılar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

- Eğitim hatası :  $\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[h(x^{(i)}) \neq y^{(i)}]$

'n' burada hatamızı hesaplamak için kullanacağımız örnek sayısıdır.

- Test hatası :  $\mathcal{E}(h)$

1, eşit değil ise  
0, eşitse

Test hatasının teori kısmı, sınıflandırıcının eğitim setinde ne kadar iyi bir sınıflandırma yaptığını tespit etmesidir.

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıktılar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

- Eğitim hatası :  $\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[h(x^{(i)}) \neq y^{(i)}]$

'n' burada hatamızı hesaplamak için kullanacağımız örnek sayısıdır.

- Test hatası :  $\mathcal{E}(h)$

1, eşit değil ise  
0, eşitse

Test hatasının teori kısmı, sınıflandırıcının eğitim setinde ne kadar iyi bir sınıflandırma yaptığını tespit etmesidir.

Ayrıca test seti için bu tespit yapılmalıdır.  
(Generalization)

# Perceptron : Temel Kavramlar

- Özellik vektörleri (Feature vectors) ve etiketler (labels) :  $x \in \mathcal{R}^d, y \in \{-1, 1\}$

$x$  sınıflandırma için tahmin yapmamızı sağlayan bir vektördür.

Çıktılar, etiketler yada hedefler

- Eğitim seti (Training set) :  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$

Denetimli öğrenmenin görevi, bize bir girdi (input) ve buna karşılık gelen istediğimiz bir çıktı (output) vermesidir.

- Sınıflandırıcı :  $h : \mathcal{R}^d \rightarrow \{-1, 1\}$ ,  $h(x) = 1$  ya da  $-1$

$$x^+ = \{x \in \mathcal{R}^d : h(x) = 1\}$$

$$x^- = \{x \in \mathcal{R}^d : h(x) = -1\}$$

Sınıflandırıcının görevi, uyguladığımız bir girdiyi belli bir noktaya haritalandırmasıdır.

- Eğitim hatası :  $\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[h(x^{(i)}) \neq y^{(i)}]$

'n' burada hatamızı hesaplamak için kullanacağımız örnek sayısıdır.

- Test hatası :  $\mathcal{E}(h)$


1, eşit değil ise  
0, eşitse

Test hatasının teori kısmı, sınıflandırıcının eğitim setinde ne kadar iyi bir sınıflandırma yaptığını tespit etmesidir.

Ayrıca test seti için bu tespit yapılmalıdır.  
(Generalization)


- Sınıflandırıcı kümesi (set of classifiers) :  $h \in \mathcal{H}$

# Eğitim Seti (Train Set)







# Eğitim Seti (Train Set)




# Eğitim Seti (Train Set)




# Sınıflandırıcı (Classifier)




# Sınıflandırıcı (Classifier)




# Sınıflandırıcı (Classifier)



# Sınıflandırıcı (Classifier)




# Sınıflandırıcı (Classifier)



Asıl mesele ise henüz  
görmediğimiz test örneklerini  
doğru bir şekilde  
sınıflandırabilmek.

# Sınıflandırıcı (Classifier)




Asıl mesele ise henüz  
görmediğimiz test örneklerini  
doğru bir şekilde  
sınıflandırabilmek.

Eğitim örneği ve test örneği  
arasında bir bağlantı kurmaya  
çalışmak.



# Sınıflandırıcı (Classifier)



Asıl mesele ise henüz  
görmediğimiz test örneklerini  
doğru bir şekilde  
sınıflandırabilmek.


Eğitim örneği ve test örneği  
arasında bir bağlantı kurmaya  
çalışmak.

Bu iki kümenin değerleri, başka  
bir kümenin alt kümesinin  
rastgele(random) değerleri


# Doğrusal Sınıflandırıcı (Linear Classifier)




# Doğrusal Sınıflandırıcı (Linear Classifier)




# Doğrusal Sınıflandırıcı (Linear Classifier)



# Doğrusal Sınıflandırıcı (Linear Classifier)




# Doğrusal Sınıflandırıcı (Linear Classifier)



2 boyutta, karar sınırimız bir çizgi,  $x$  vektörü 1 boyutlu olsaydı karar sınırimız bir nokta olacaktı. 3 boyutta ise bir düzlem...

# Doğrusal Sınıflandırıcı (Linear Classifier)




Doğrusal sınıflandırıcı için  
karar sınırımızı değiştirebiliriz.

# Orjinden Geçen Doğrusal Sınıflandırıcı






# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı




$x : w_1x_1 + w_2x_2 = 0$  karar sınırı(decision boundry)

$x : w \cdot x = 0$  karar sınırı(decision boundry)


# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı



# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı







# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı




# Orjinden Geçen Doğrusal Sınıflandırıcı




# Doğrusal Sınıflandırıcılar




# Doğrusal Sınıflandırıcılar



# Doğrusal Sınıflandırıcılar




# Doğrusal Sınıflandırıcılar







# Doğrusal Sınıflandırıcılar




# Doğrusal Sınıflandırıcılar



# Doğrusal Sınıflandırıcılar




# Doğrusal Sınıflandırıcılar




# Doğrusal Ayırma : Örnek




# Doğrusal Ayırma : Örnek



# Doğrusal Ayırma : Örnek




# Doğrusal Ayırma : Örnek







# Doğrusal Ayırma : Örnek



# Doğrusal Ayırma : Örnek



# Doğrusal Ayırma : Örnek



# Doğrusal Ayırma

## Tanım:

Eğitim örnekleri  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$  *doğrusal ayrılabilir* eğer ki uygun bir parametre vektörü  $\hat{w}$  ve denkleştirme parametresi (offset parameter)  $\hat{b}$  aşağıda bulunan denklemdeki koşula uyuyor ise;

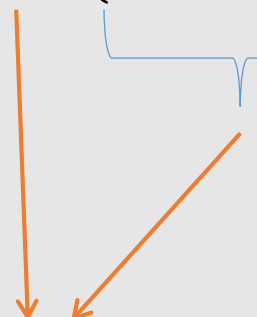
$$y^{(i)}(\hat{w} \cdot x^{(i)} + \hat{b}) > 0, \quad i = 1, \dots, n$$

# Doğrusal Ayırma

## Tanım:

Eğitim örnekleri  $S_n = \{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}$  *doğrusal ayrılabilir* eğer ki uygun bir parametre vektörü  $\hat{w}$  ve denkleştirme parametresi (offset parameter)  $\hat{b}$  aşağıda bulunan denklemdeki koşula uyuyor ise;

$$y^{(i)}(\hat{w} \cdot x^{(i)} + \hat{b}) > 0, \quad i = 1, \dots, n$$



Sonuçların işaretleri birbirlerine eşit olmalı, aksi halde doğrusal ayırmamız mümkün değil.

# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası(orjinden)

# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası(orjinden)

$$\varepsilon_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket h(x^{(i)}) \neq y^{(i)} \rrbracket$$

# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası(orjinden)

$$\varepsilon_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket h(x^{(i)}) \neq y^{(i)} \rrbracket$$

Eğitim hatası





# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası(orjinden)

$$\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket h(x^{(i)}) \neq y^{(i)} \rrbracket$$

$$\mathcal{E}_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası(orjinden)

$$\varepsilon_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket h(x^{(i)}) \neq y^{(i)} \rrbracket$$

$$\varepsilon_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

Orjinden geçen doğrusal  
sınıflandırıcının hatası



# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası(orjinden)

$$\varepsilon_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket h(x^{(i)}) \neq y^{(i)} \rrbracket$$

$$\varepsilon_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

Orjinden geçen doğrusal  
sınıflandırıcının hatası

Verilen  $y^{(i)}$  etiketinde, bu  
etiketin işareti ( $w \cdot x^{(i)}$ ) iç  
çarpımının sonucunda elde  
edilen işaret ile aynı olmalı.

# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası(orjinden)

$$\varepsilon_n(h) = \frac{1}{n} \sum_{i=1}^n \llbracket h(x^{(i)}) \neq y^{(i)} \rrbracket$$

$$\varepsilon_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

Orjinden geçen doğrusal  
sınıflandırıcının hatası

Eğer  $y^{(i)} w \cdot x^{(i)} = 0$  ise bu örnek tam karar sınırının üzerinde olduğu anlamına gelir. Ve bunu bir hata olarak kabul ederiz. Çünkü hangi yöne doğru sınıflandırma yapmamız gerektiğini bilmiyoruz.

Verilen  $y^{(i)}$  etiketinde, bu etiketin işareti ( $w \cdot x^{(i)}$ ) iç çarpımının sonucunda elde edilen işaret ile aynı olmalı.

# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası

$$\mathcal{E}_n(w, b) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[y^{(i)}(w \cdot x^{(i)} + b) \leq 0]$$

# Doğrusal Sınıflandırıcıyı Öğrenme

- Doğrusal sınıflandırma için eğitim hatası

$$\varepsilon_n(w, b) = \frac{1}{n} \sum_{i=1}^n \underbrace{\llbracket y^{(i)}(w \cdot x^{(i)} + b) \leq 0 \rrbracket}$$


0 yada negatif olursa hata  
olarak kabul edilir.  
Pozitif olursa hata yoktur.

# Perceptron Öğrenme Algoritması

$$w = 0 \text{ (vektör)}$$

# Perceptron Öğrenme Algoritması

$w = 0$  (*vektör*)



Parametremizi sıfıra eşitleriz.



# Perceptron Öğrenme Algoritması

$w = 0$  (vektör)

***if***  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  ***then***

$w = w + y^{(i)}x^{(i)}$

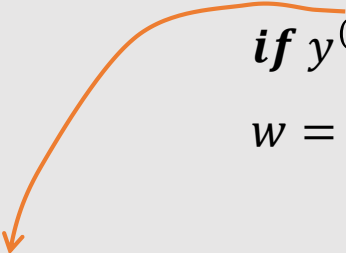
# Perceptron Öğrenme Algoritması

$w = 0$  (vektör)

**if**  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  **then**

$w = w + y^{(i)}x^{(i)}$

$i$ . örnek ( $i^{th}$  example)



# Perceptron Öğrenme Algoritması

$w = 0$  (vektör)

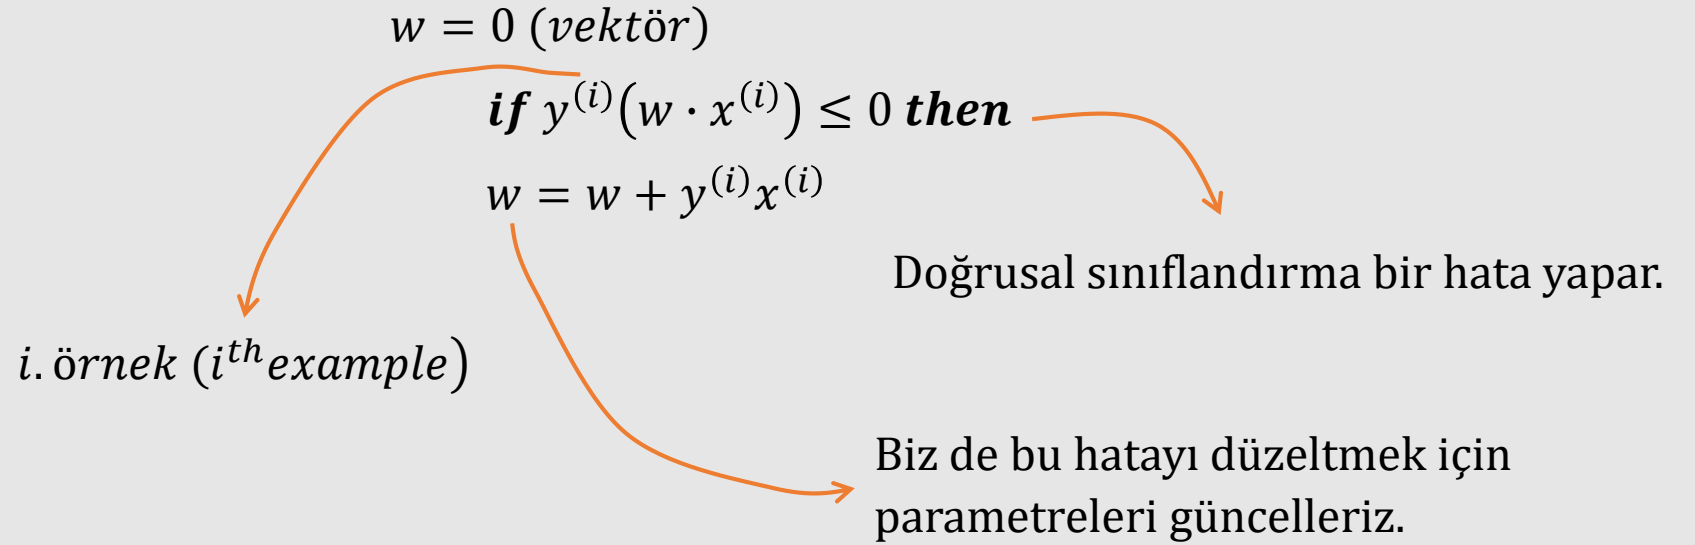
**if**  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  **then**

$w = w + y^{(i)}x^{(i)}$

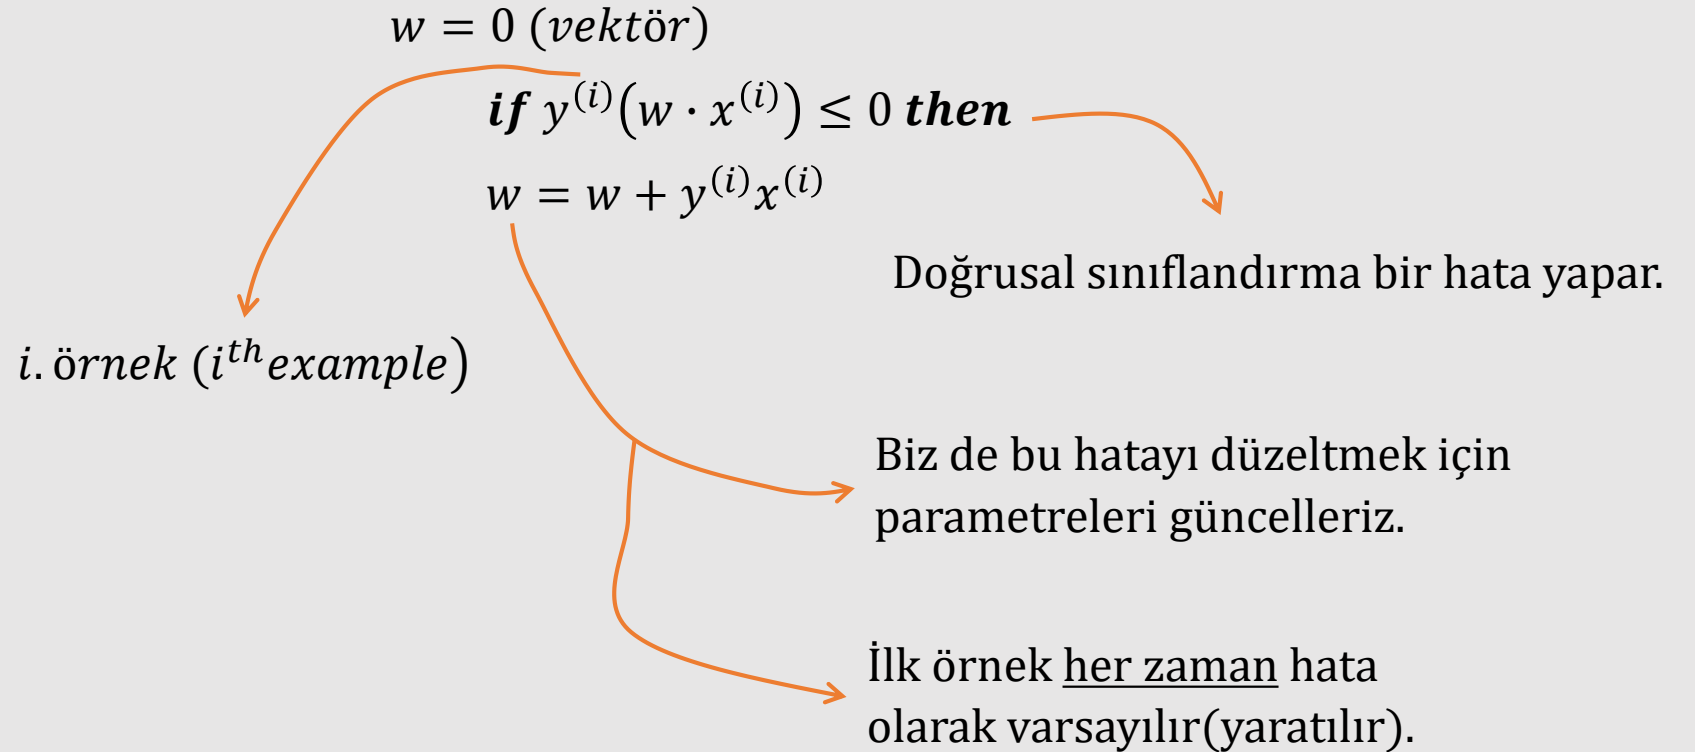
$i$ . örnek ( $i^{th}$  example)

Doğrusal sınıflandırma bir hata yapar.

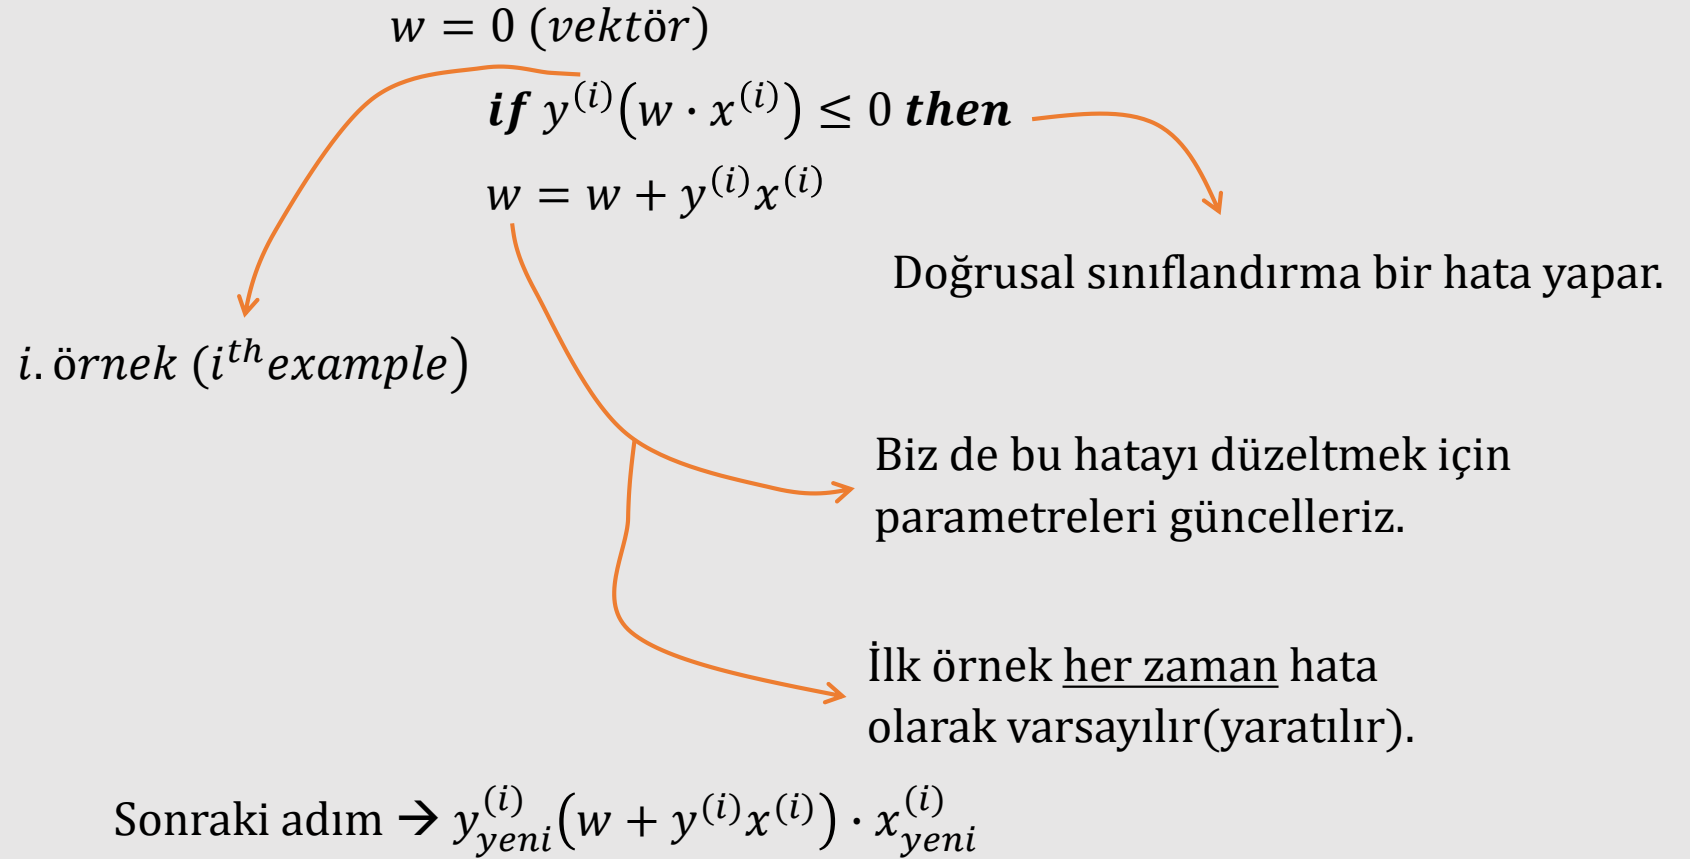
# Perceptron Öğrenme Algoritması



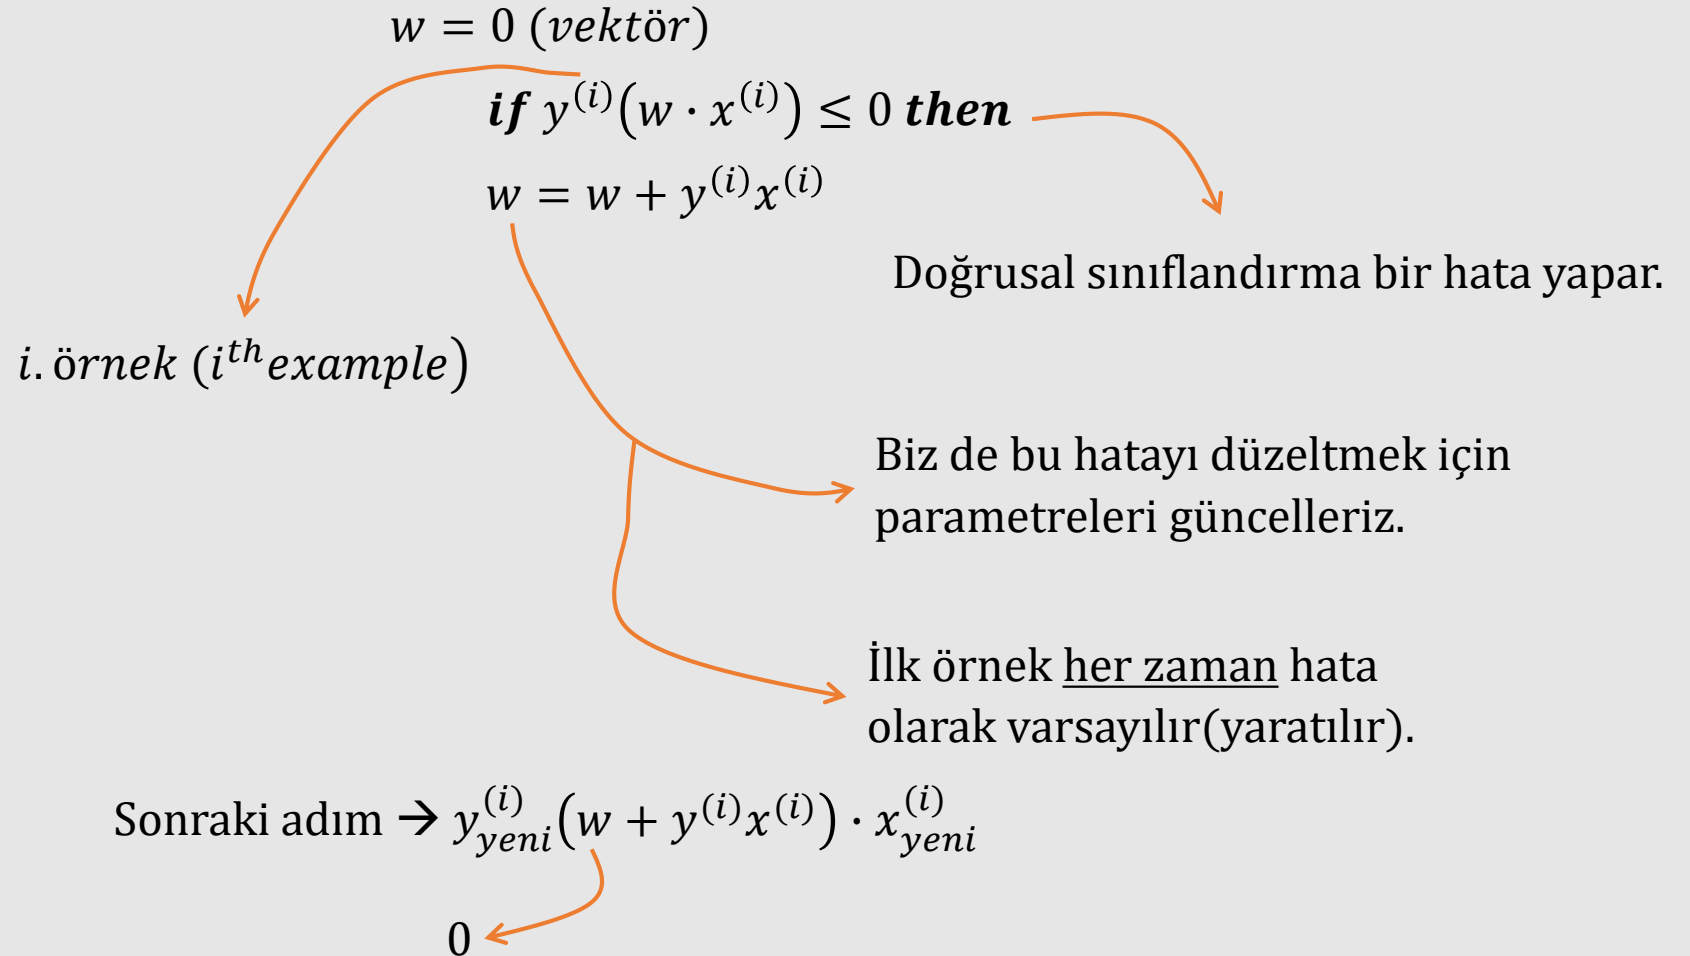
# Perceptron Öğrenme Algoritması




# Perceptron Öğrenme Algoritması



# Perceptron Öğrenme Algoritması

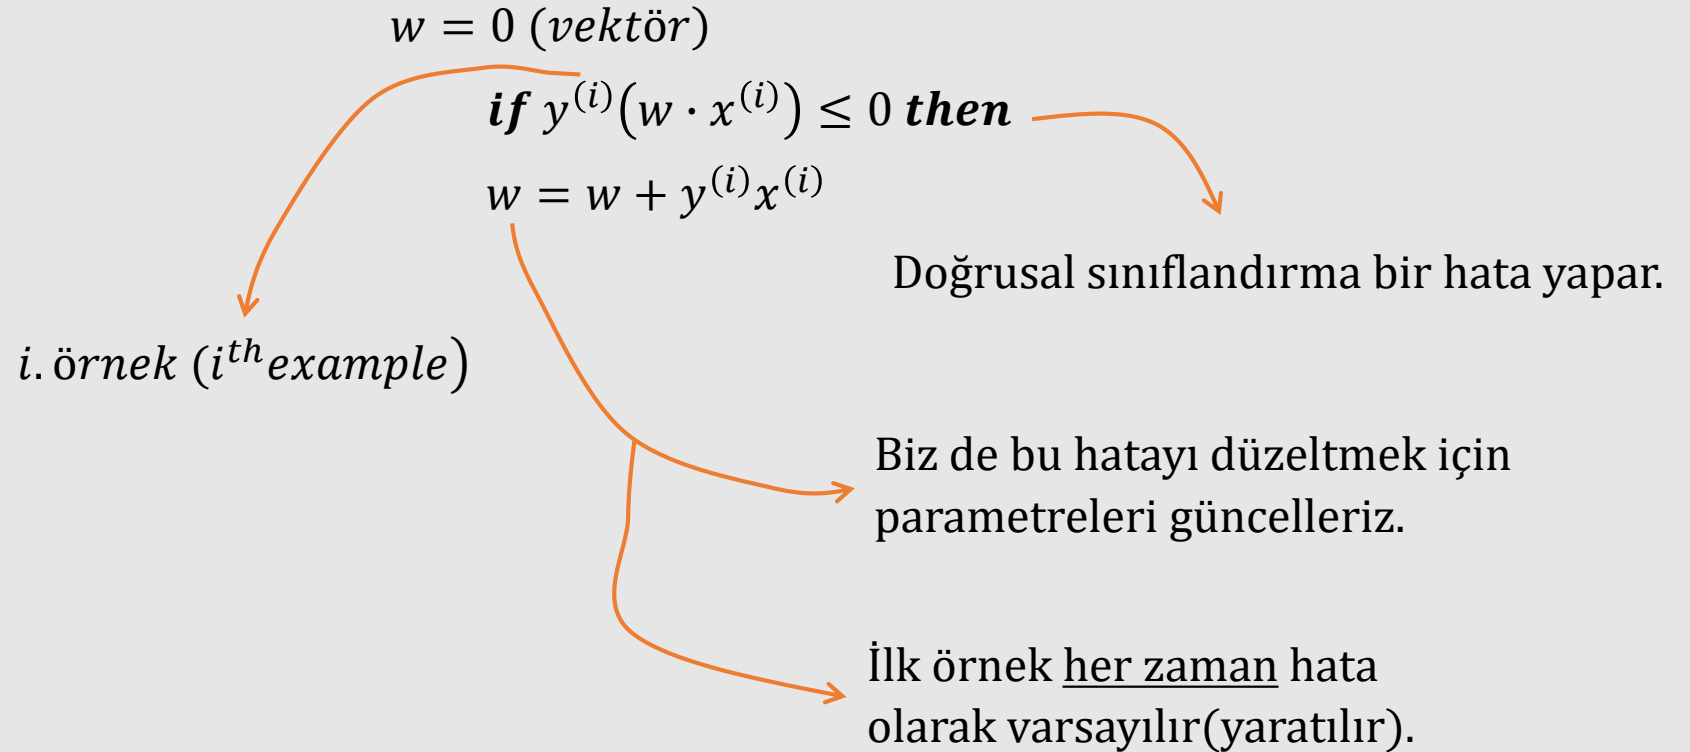


# Perceptron Öğrenme Algoritması





# Perceptron Öğrenme Algoritması



Sonraki adım  $\rightarrow y_{yeni}^{(i)}(w + y^{(i)}x^{(i)}) \cdot x_{yeni}^{(i)} = \|x^{(i)}\|^2 > 0$

# Perceptron Öğrenme Algoritması


$w = 0$  (vektör)

***for***  $i = 1, \dots, n$  ***do***

***if***  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  ***then***

$w = w + y^{(i)}x^{(i)}$

# Perceptron Öğrenme Algoritması

$w = 0$  (vektör)  Bütün eğitim örnek sayısı

***for***  $i = 1, \dots, n$  ***do***

***if***  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  ***then***

$w = w + y^{(i)}x^{(i)}$

# Perceptron Öğrenme Algoritması

$w = 0$  (vektör)

**for**  $i = 1, \dots, n$  **do**

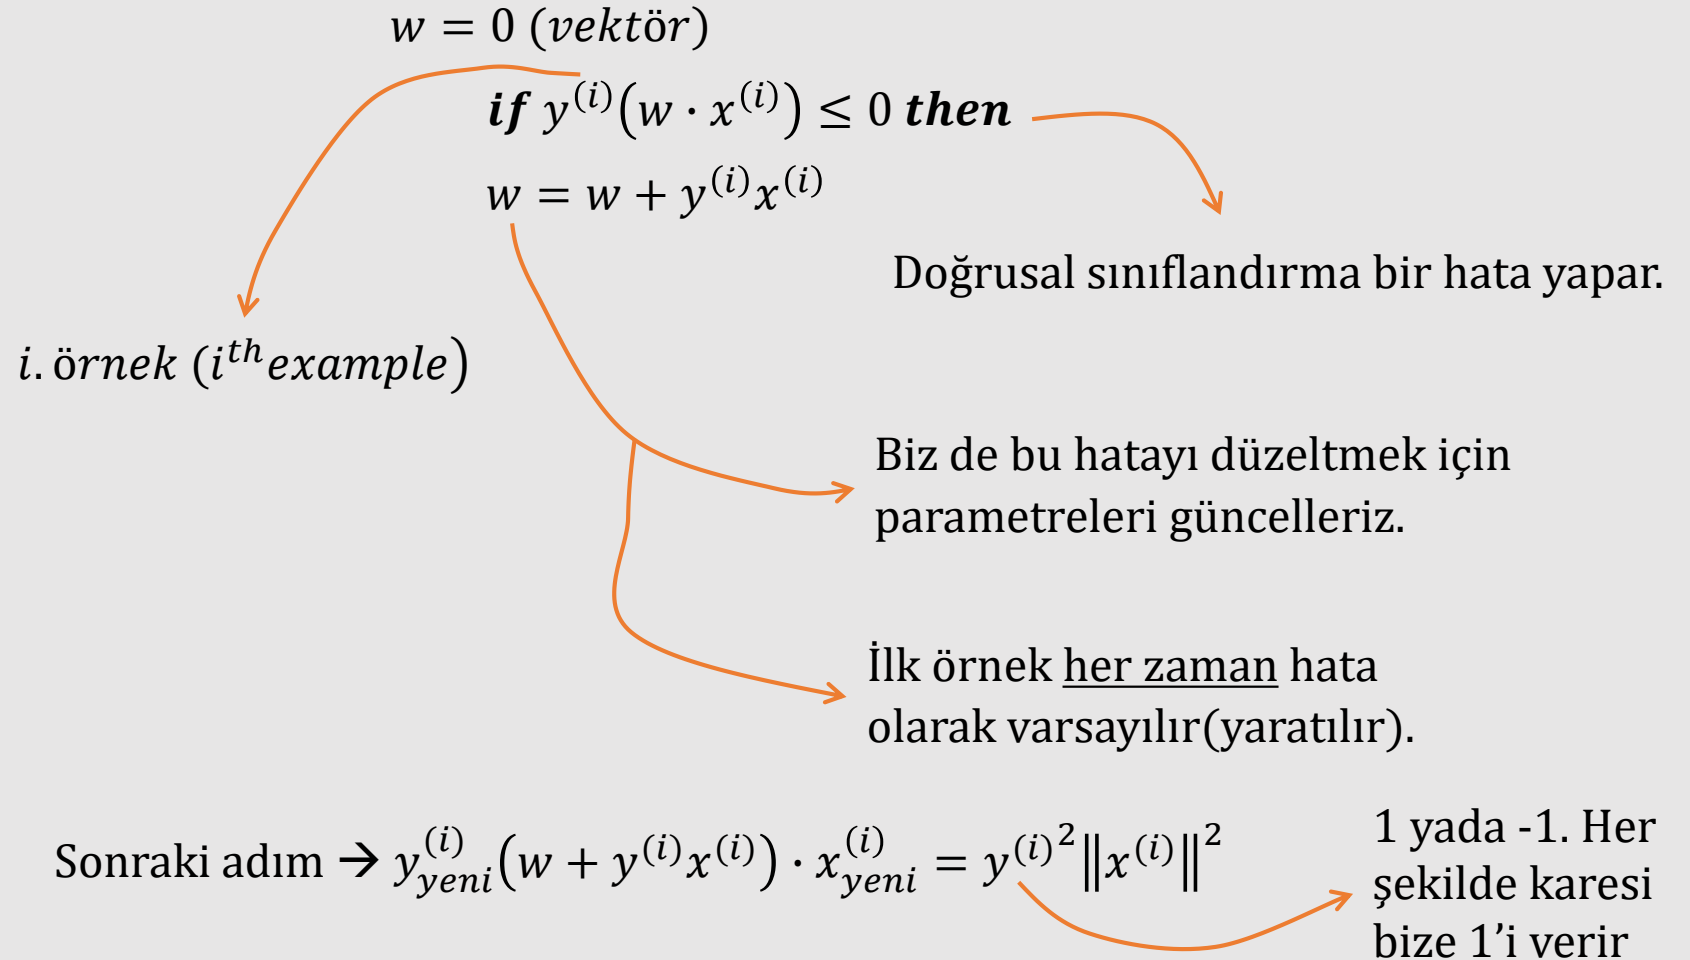
**if**  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  **then**

$w = w + y^{(i)}x^{(i)}$

Bütün eğitim örnek sayısı

Eğer  $i$ . Örneğimiz bir hata  
ise(ilk başta her zaman  
hata!), güncelleme yaparız.

# Perceptron Öğrenme Algoritması



# Perceptron Öğrenme Algoritması

```
procedure PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )  
     $w = 0$  (vektör)  
    for  $t = 1, \dots, T$  do  
        for  $i = 1, \dots, n$  do  
            if  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  then  
                 $w = w + y^{(i)}x^{(i)}$   
    return  $w$ 
```

# Perceptron Öğrenme Algoritması

**procedure** PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )

$w = 0$  (vektör)


**for**  $t = 1, \dots, T$  **do**

**for**  $i = 1, \dots, n$  **do**

**if**  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  **then**

$w = w + y^{(i)}x^{(i)}$

**return**  $w$



Birbirinden farklı eğitim örnekleri parametreleri farklı yönlerde güncelleyebileceğinden dolayı, sonraki güncellemeler bir önceki güncellemelerin bulduğu sınıflandırmaları ortadan kaldırabilir.

# Perceptron Öğrenme Algoritması

**procedure** PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )

$w = 0$  (vektör)

**for**  $t = 1, \dots, T$  **do**

**for**  $i = 1, \dots, n$  **do**

**if**  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  **then**

$w = w + y^{(i)}x^{(i)}$

**return**  $w$

Birbirinden farklı eğitim örnekleri parametreleri farklı yönlerde güncelleyebileceğinden dolayı, sonraki güncellemeler bir önceki güncellemelerin bulduğu sınıflandırmaları ortadan kaldırabilir.

T parametresi bize eğitim setinde kaç defa tekrar ettiğimizi belirtir.



# Perceptron Öğrenme Algoritması

**procedure** PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )

$w = 0$  (vektör)

**for**  $t = 1, \dots, T$  **do**

**for**  $i = 1, \dots, n$  **do**

**if**  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  **then**


$w = w + y^{(i)}x^{(i)}$

**return**  $w$

Birbirinden farklı eğitim örnekleri parametreleri farklı yönlerde güncelleyebileceğinden dolayı, sonraki güncellemeler bir önceki güncellemelerin bulunduğu sınıflandırmaları ortadan kaldırabilir.

T parametresi bize eğitim setinde kaç defa tekrar ettiğimizi belirtir.

Perceptron, bunu bir çözüm olarak bulabilir.



# Perceptron Öğrenme Algoritması

**procedure** PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )

$w = 0$  (vektör)

**for**  $t = 1, \dots, T$  **do**

**for**  $i = 1, \dots, n$  **do**

**if**  $y^{(i)}(w \cdot x^{(i)}) \leq 0$  **then**


$w = w + y^{(i)}x^{(i)}$

**return**  $w$

# epoch


T parametresi  
bize eğitim  
setinde kaç defa  
tekrar ettiğimizi  
belirtir.

Birbirinden farklı eğitim örnekleri parametreleri farklı yönlerde güncelleyebileceğinden dolayı, sonraki güncellemeler bir önceki güncellemelerin bulunduğu sınıflandırmaları ortadan kaldırabilir.




Bunu da bir çözüm olarak bulabilir.


# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek



# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek







# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek



# Perceptron Algoritması : Geometrik Örnek




# Perceptron Algoritması : Geometrik Örnek





# Perceptron Algoritması : Geometrik Örnek



# Perceptron Fonksiyonu

$$f(x) = \begin{cases} 1, & w \cdot x + b > 0 \\ 0, & \text{diğer} \end{cases}$$

# Perceptron Öğrenme Algoritması (Offset ile)

```
procedure PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )  
     $w = 0$  (vektör)  
    for  $t = 1, \dots, T$  do  
        for  $i = 1, \dots, n$  do  
            if  $y^{(i)}(w \cdot x^{(i)} + b) \leq 0$  then  
                 $w = w + y^{(i)}x^{(i)}$   
                 $b = b + y^{(i)}$   
    return  $w, b$ 
```

# Perceptron Öğrenme Algoritması (Offset ile)

**procedure** PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )

$w = 0$  (vektör)

**for**  $t = 1, \dots, T$  **do**

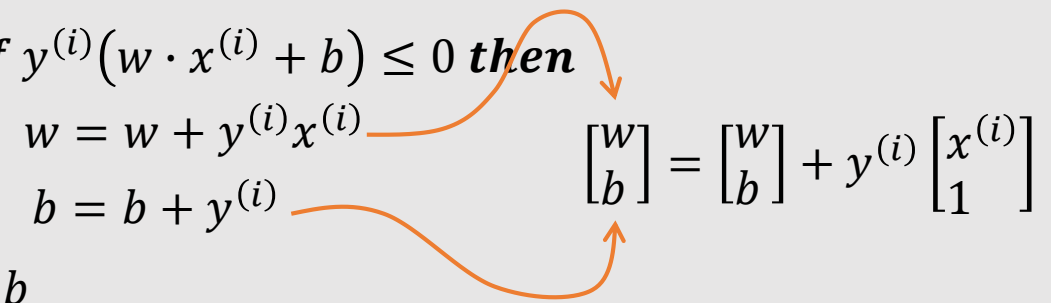
**for**  $i = 1, \dots, n$  **do**

**if**  $y^{(i)}(w \cdot x^{(i)} + b) \leq 0$  **then**

$w = w + y^{(i)}x^{(i)}$

$b = b + y^{(i)}$

**return**  $w, b$



$$\begin{bmatrix} w \\ b \end{bmatrix} = \begin{bmatrix} w \\ b \end{bmatrix} + y^{(i)} \begin{bmatrix} x^{(i)} \\ 1 \end{bmatrix}$$

The diagram illustrates the vector update equation. Two orange arrows originate from the code: one from  $w = w + y^{(i)}x^{(i)}$  pointing to the  $w$  component of the vector, and another from  $b = b + y^{(i)}$  pointing to the  $b$  component. The vector  $\begin{bmatrix} x^{(i)} \\ 1 \end{bmatrix}$  is shown with a 1 at the bottom, representing the bias term.

# Perceptron Öğrenme Algoritması (Offset ile)

**procedure** PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, T$ )

$w = 0$  (vektör)

**for**  $t = 1, \dots, T$  **do**

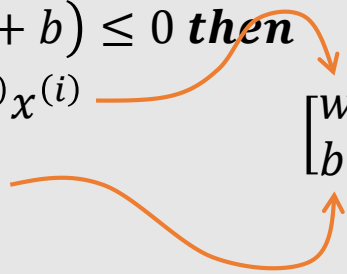
**for**  $i = 1, \dots, n$  **do**

**if**  $y^{(i)}(w \cdot x^{(i)} + b) \leq 0$  **then**

$w = w + y^{(i)}x^{(i)}$

$b = b + y^{(i)}$

**return**  $w, b$


$$\begin{bmatrix} w \\ b \end{bmatrix} = \begin{bmatrix} w \\ b \end{bmatrix} + y^{(i)} \begin{bmatrix} x^{(i)} \\ 1 \end{bmatrix}$$

$$w \cdot x + b = \begin{bmatrix} w \\ b \end{bmatrix} \cdot \begin{bmatrix} x \\ 1 \end{bmatrix}$$

# Perceptron Öğrenme Algoritması (Gradient Descent)

**procedure** PERCEPTRON( $\{(x^{(i)}, y^{(i)}), i = 1, \dots, n\}, \alpha = 0.01, epochs = 10$ )

$w = 0$  (vektör)

**for**  $t = 1, \dots, epochs$  **do**

**for**  $i = 1, \dots, n$  **do**


**if**  $y^{(i)}(w \cdot x^{(i)} + b) \leq 0$  **then**

$$w = w - \frac{1}{n} * \alpha \sum_i^n y^{(i)}(w \cdot x^{(i)} + b) \cdot x^{(i)}$$

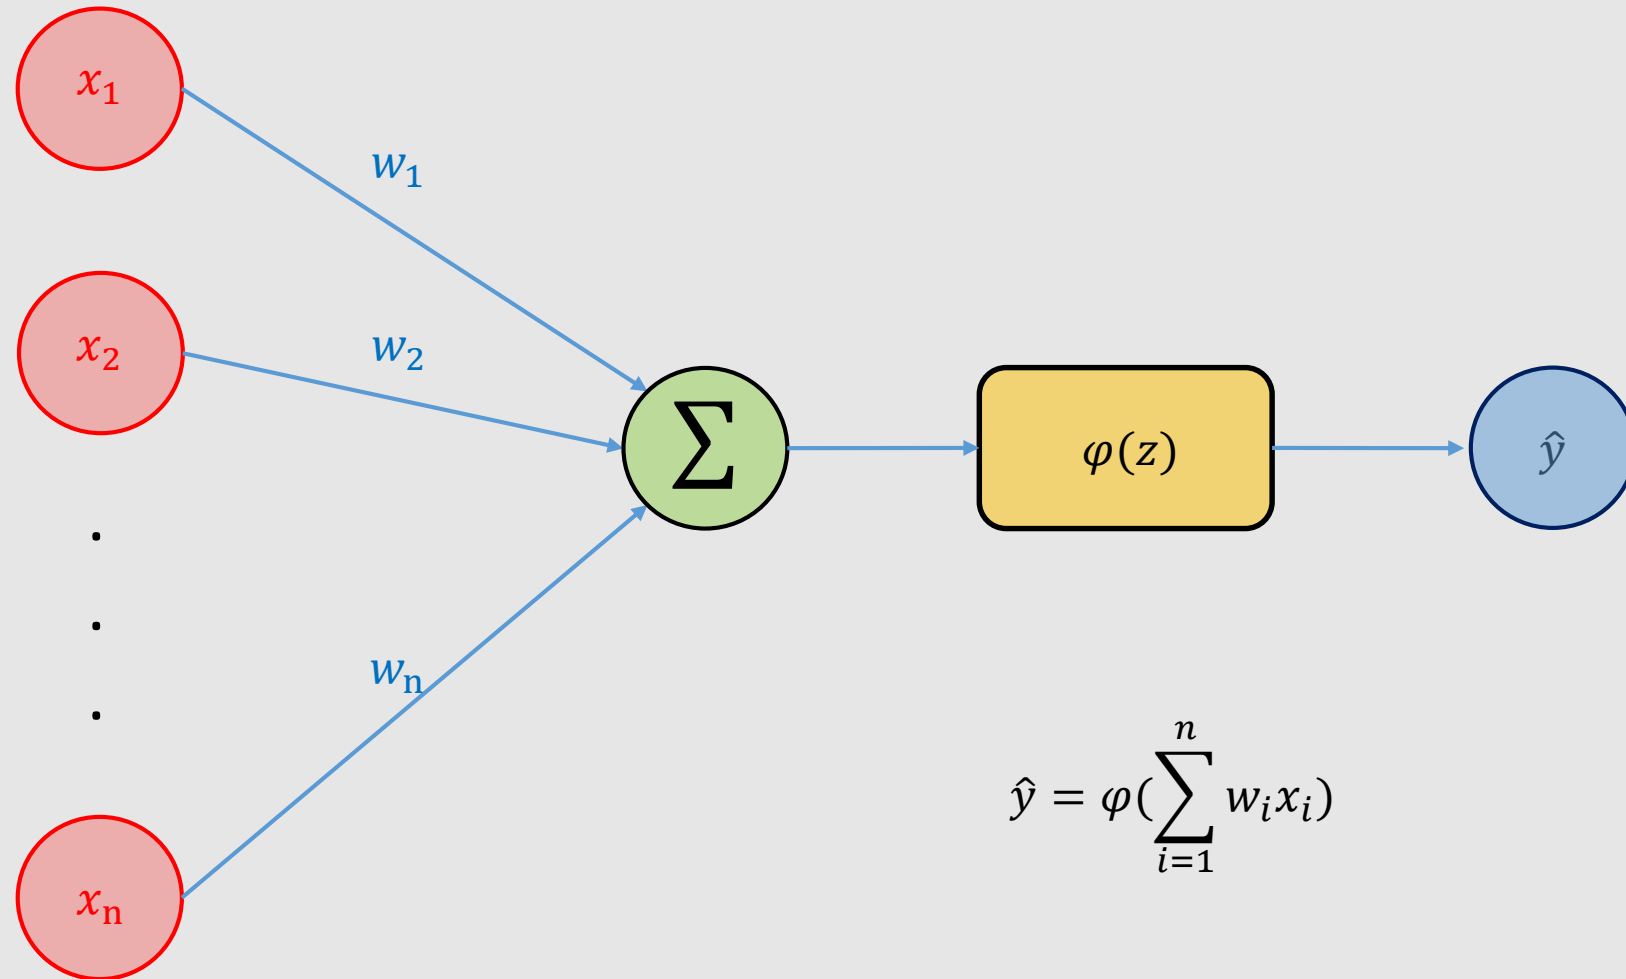
$$b = b - \frac{1}{n} * \alpha \sum_i^n y^{(i)}(w \cdot x^{(i)} + b)$$

**return**  $w, b$

# Perceptron : YSA ile gösterilişi

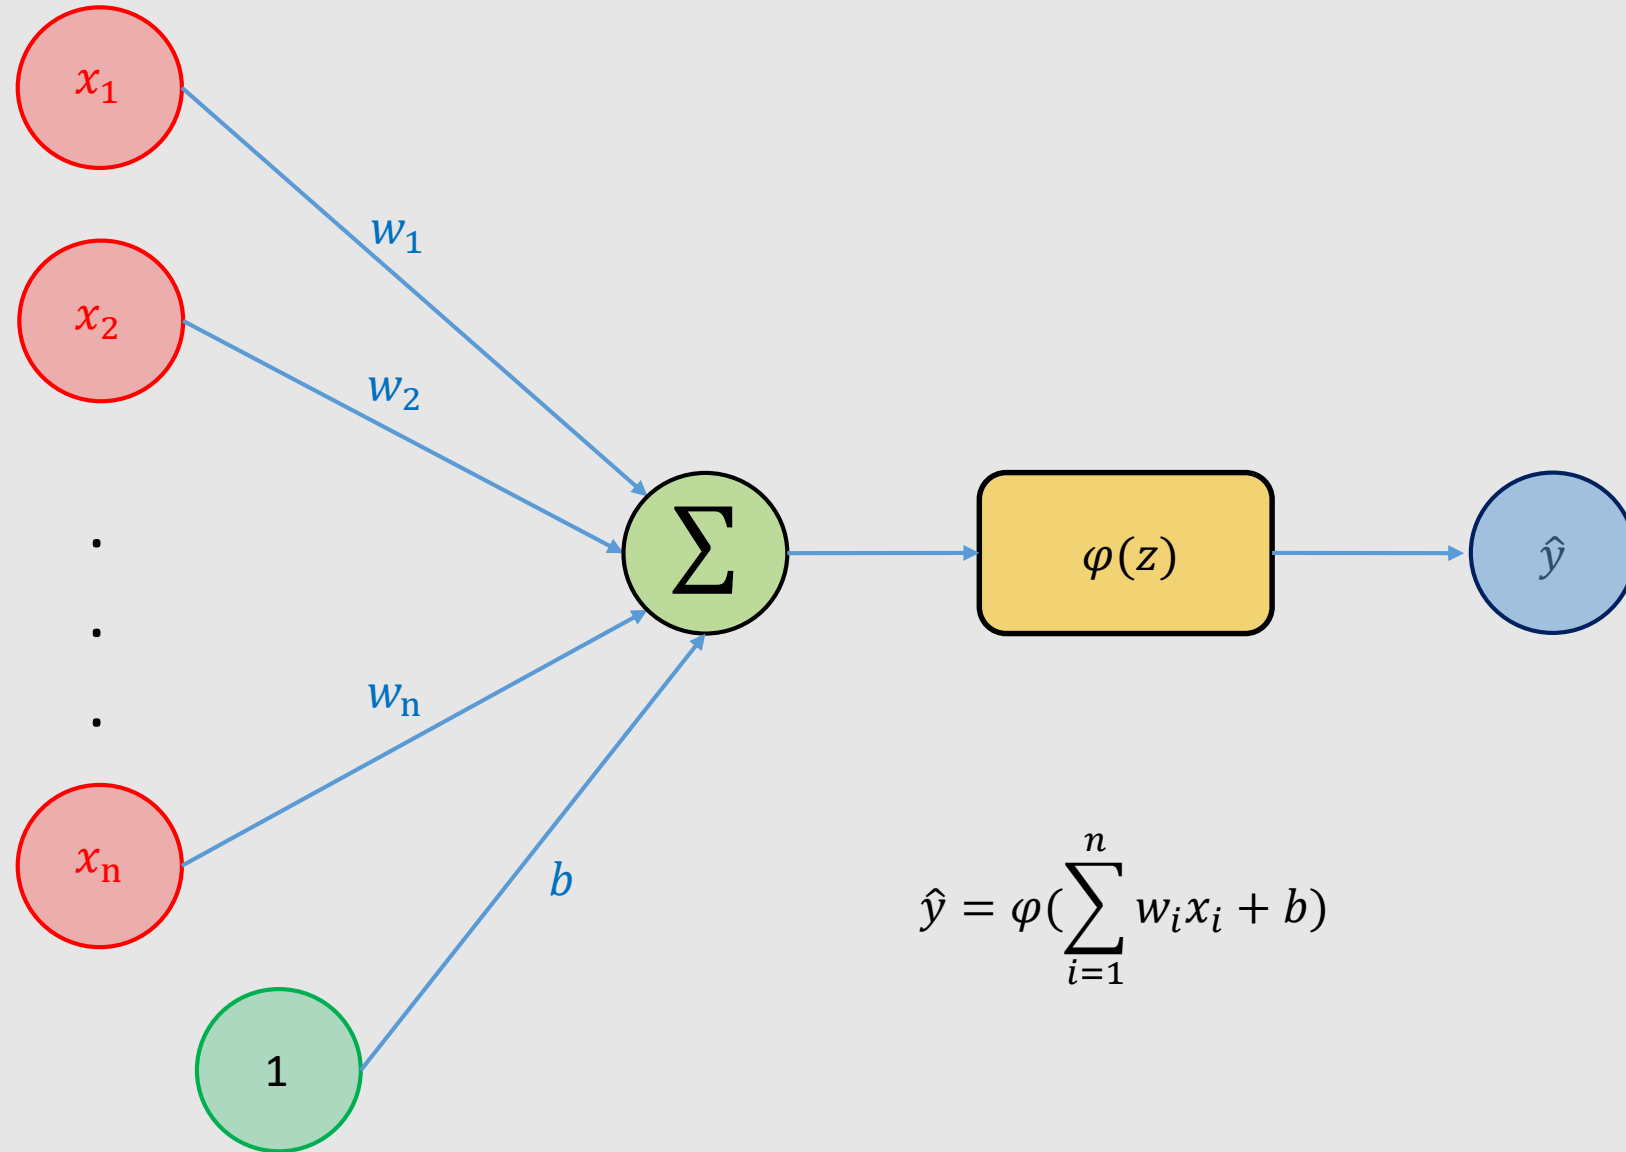


# Perceptron : Forward Propagation

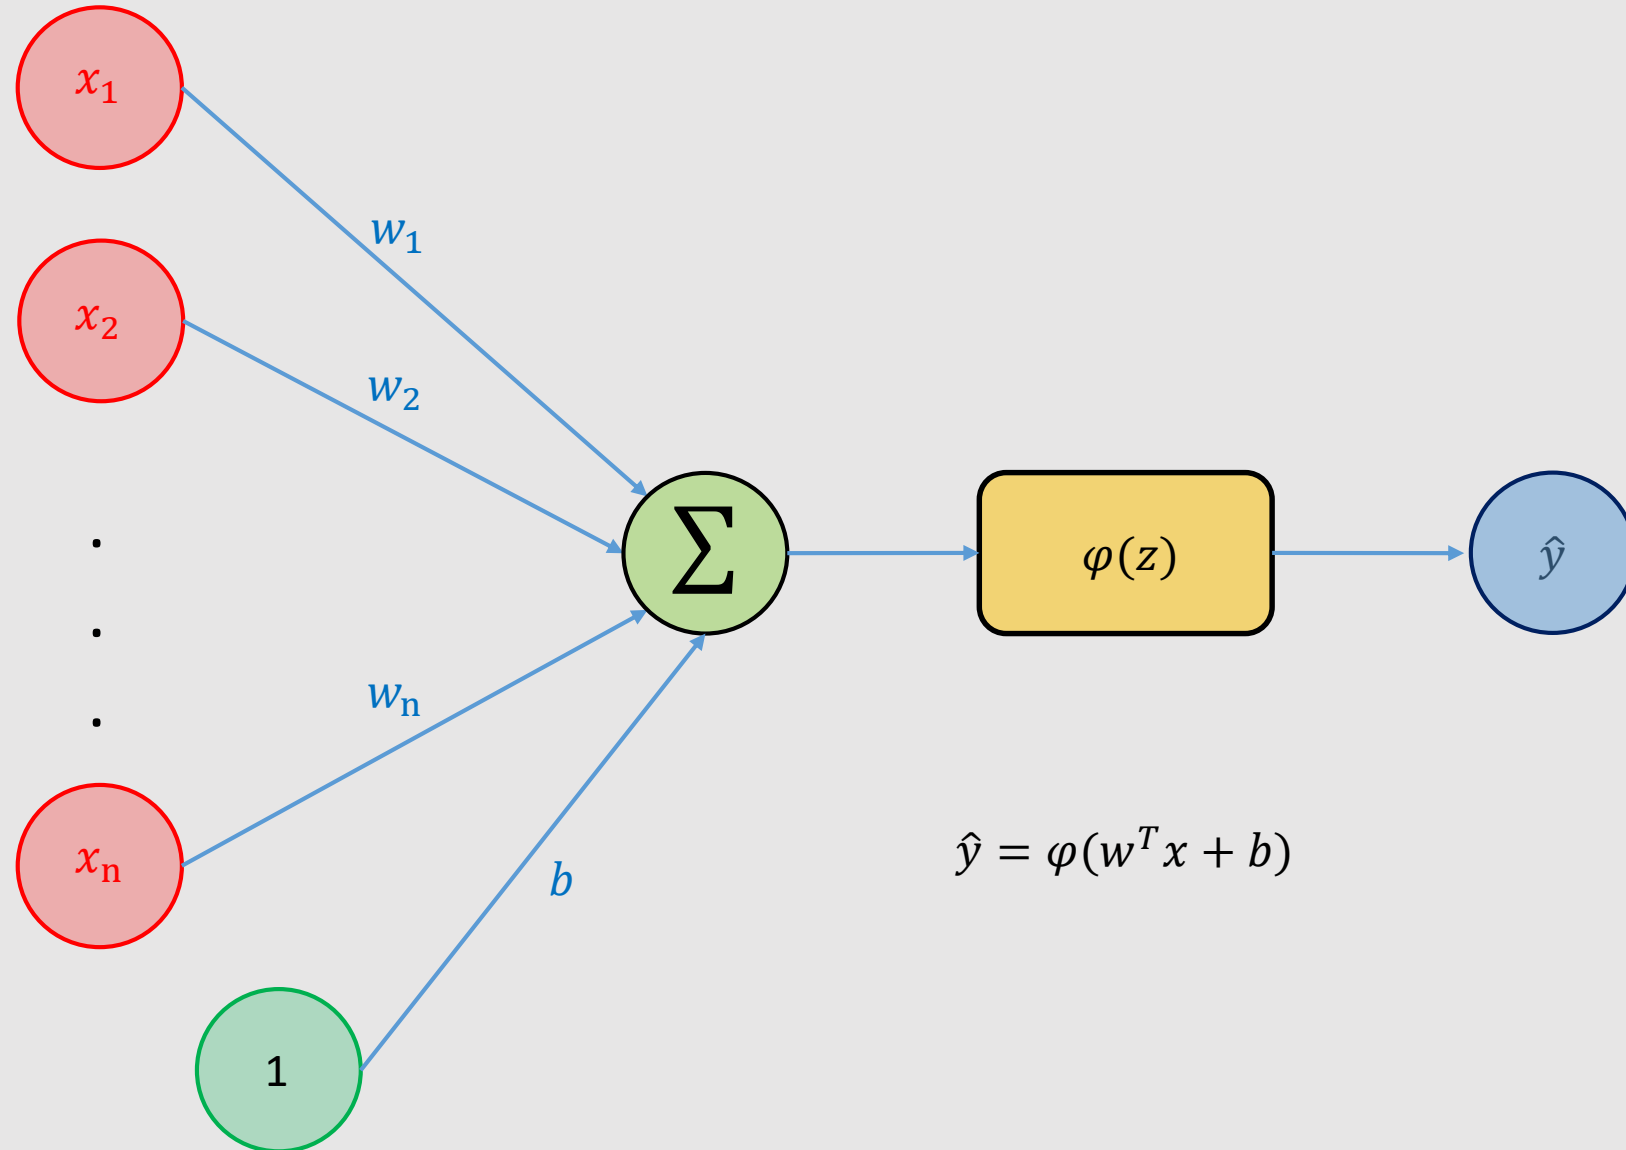




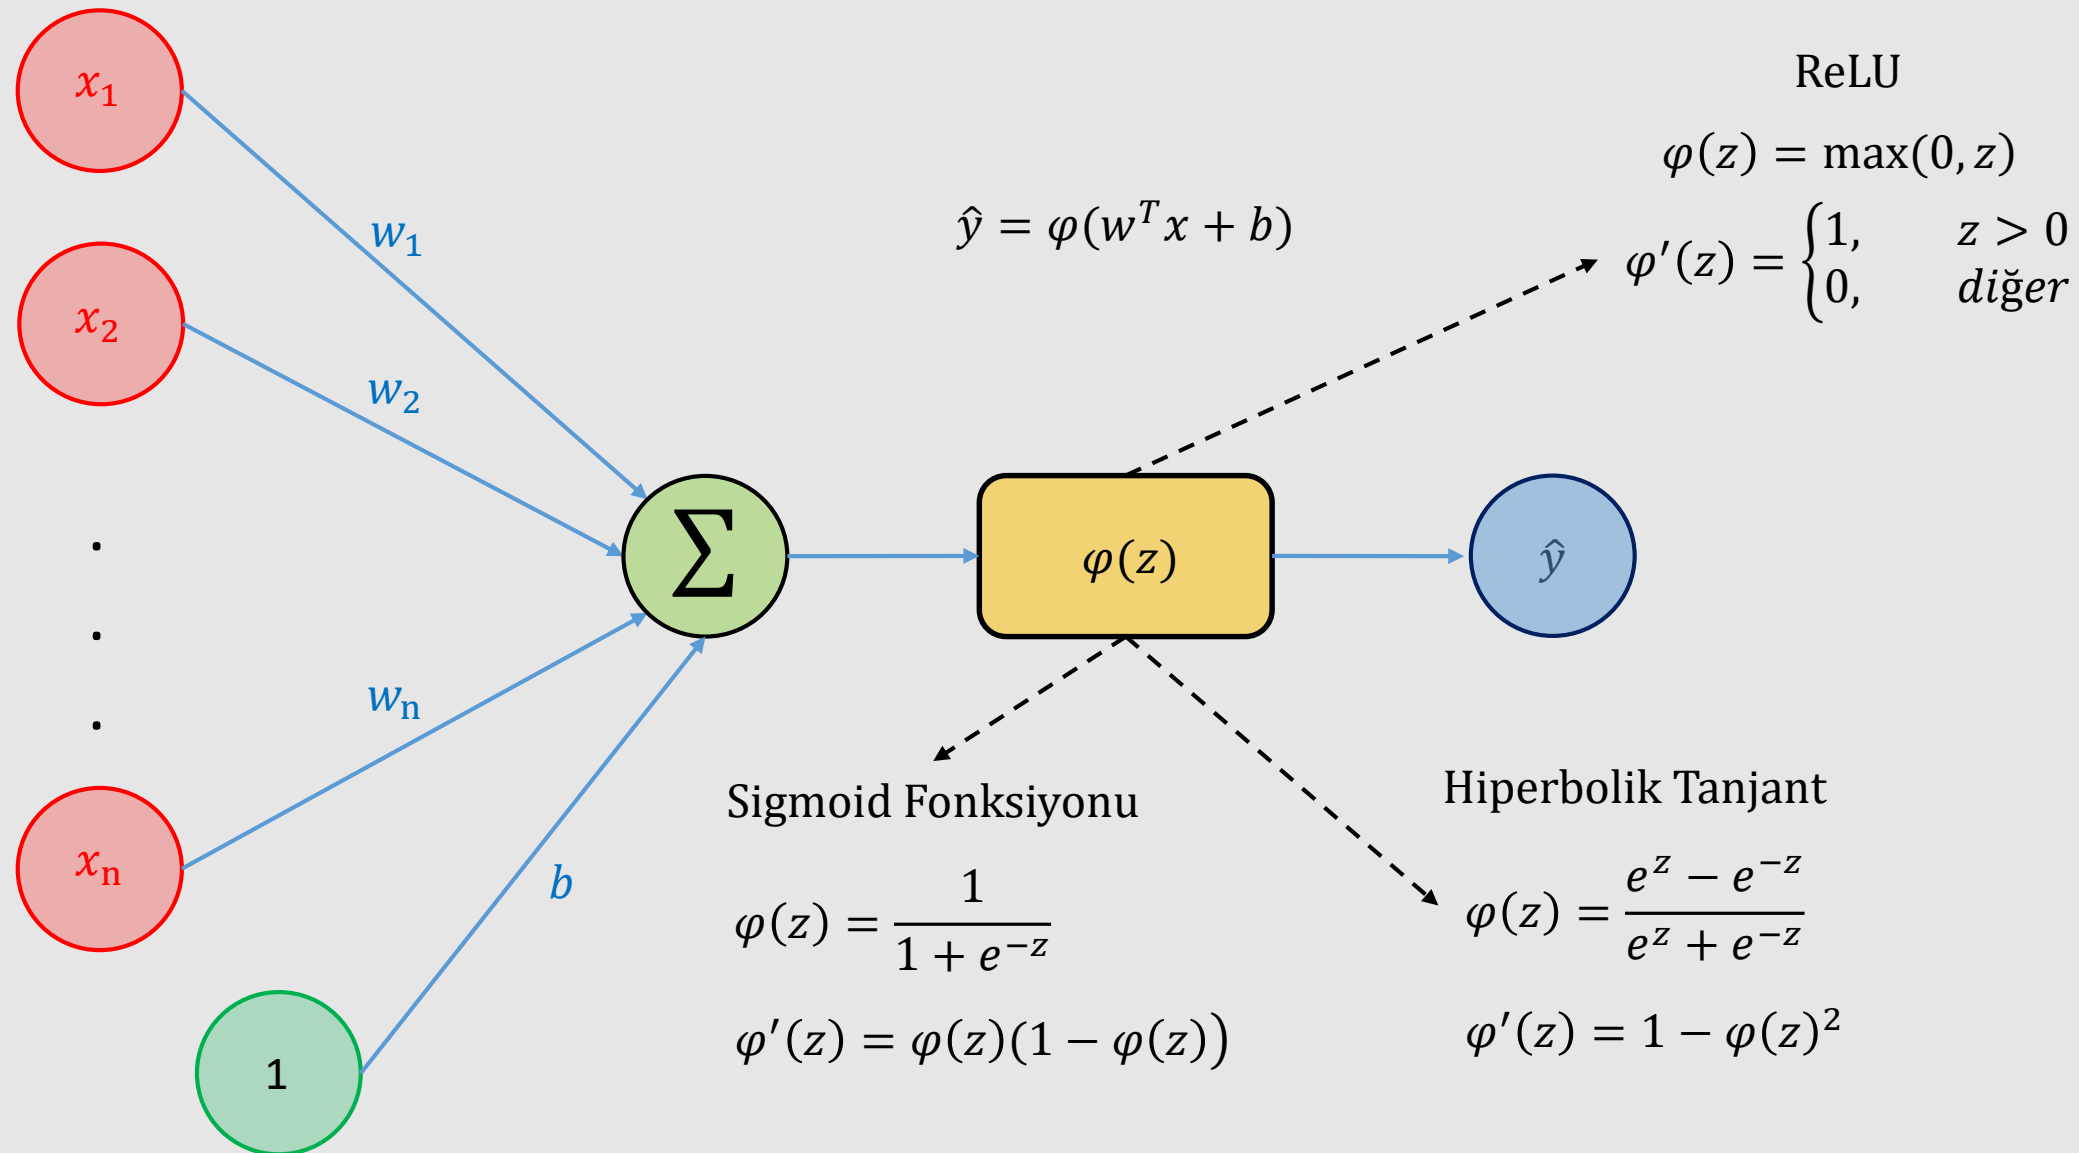
# Perceptron : Forward Propagation




# Perceptron : Forward Propagation



# Perceptron : Forward Propagation




# Aktivasyon Fonksiyonlarının Önemi



Buradaki 4 noktayı da ayıracak bir doğrusal sınıflandırıcı bulunmamakta.


# Aktivasyon Fonksiyonlarının Önemi



Buradaki 4 noktayı da ayıracak bir doğrusal sınıflandırıcı bulunmamakta.

Bu sınıflandırmayı doğru bir şekilde yapabilmek için aktivasyon fonksiyonlarına ihtiyaç duyarız.

# Aktivasyon Fonksiyonlarının Önemi




Buradaki 4 noktayı da ayıracak bir doğrusal sınıflandırıcı bulunmamakta.

Bu sınıflandırmayı doğru bir şekilde yapabilmek için aktivasyon fonksiyonlarına ihtiyaç duyarız.

Farklı bir boyuta dönüştürüp analiz yapabilmek için

# Aktivasyon Fonksiyonlarının Önemi



Doğrusal olmayan bir aktivasyon fonksiyonu uyguladığımızda, ayırma işlemini bu şekilde ayırabiliriz. (Aktivasyon Fonksiyonu)

# Örnek

Aşağıda verilen küçük veri seti bilgilerine göre orjinden geçen bir perceptron algoritması oluşturmaya çalışın.

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(1)} = [1, 0], \quad y^{(2)} = -1$$

$$x^{(1)} = [-1, 1.5], y^{(3)} = 1$$



# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(1)} = [1, 0], \quad y^{(2)} = -1$$

$$x^{(1)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$


$$x^{(1)} = [1, 0], y^{(2)} = -1$$

$$x^{(1)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

Weight vektörü ilk değeri 0.

Algoritma otomatikmen hata olarak algılayacak.



# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(2)} = [1, 0], y^{(2)} = -1$$

$$x^{(3)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

Weight vektörü ilk değeri 0.

Algoritma otomatikmen hata olarak algılayacak.

$$\mathcal{E}_n(w) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[y^{(i)} w \cdot x^{(i)} \leq 0]$$

# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(2)} = [1, 0], y^{(2)} = -1$$

$$x^{(3)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

Weight vektörü ilk değeri 0.

Algoritma otomatikmen hata olarak algılayacak.

$$\mathcal{E}_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

$$w^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \longrightarrow w^{(0)} \cdot x^{(1)} = 0$$

# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(2)} = [1, 0], y^{(2)} = -1$$

$$x^{(3)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

Weight vektörü ilk değeri 0.

Algoritma otomatikmen hata olarak algılayacak.

$$\mathcal{E}_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

$$w^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \longrightarrow w^{(0)} \cdot x^{(1)} = 0 \longrightarrow 0\text{'a eşit. Hata var!}$$

# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(1)} = [1, 0], y^{(2)} = -1$$

$$x^{(1)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

Weight vektörü ilk değeri 0.

Algoritma otomatikmen hata olarak algılayacak.

$$\mathcal{E}_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

$$w^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \longrightarrow w^{(0)} \cdot x^{(1)} = 0 \longrightarrow 0\text{'a eşit. Hata var!}$$

$$w^{(1)} = w^{(0)} + y^{(1)} x^{(1)} = 0 + 1 \begin{bmatrix} -1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} -1 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(1)} = [1, 0], \quad y^{(2)} = -1$$

$$x^{(1)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

$$\varepsilon_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

$$w^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(1)} = [1, 0], \quad y^{(2)} = -1$$

$$x^{(1)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

$$\varepsilon_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

$$w^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$w^{(1)} \cdot x^{(2)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = -1 \longrightarrow -1 > 0, \text{hata yok}$$



# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(2)} = [1, 0], y^{(2)} = -1$$

$$x^{(3)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

$$\mathcal{E}_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

$$w^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$w^{(1)} \cdot x^{(2)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = -1 \longrightarrow -1 > 0, \text{hata yok}$$

$$w^{(1)} \cdot x^{(3)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \cdot \begin{bmatrix} -1 \\ 1.5 \end{bmatrix} = -0.5 \longrightarrow -0.5 < 0, \text{hata var, güncelle!}$$

# Çözüm

$$x^{(1)} = [-1, -1], y^{(1)} = 1$$

$$x^{(2)} = [1, 0], y^{(2)} = -1$$

$$x^{(3)} = [-1, 1.5], y^{(3)} = 1$$

$$w^{(0)} = 0$$

$$\mathcal{E}_n(w) = \frac{1}{n} \sum_{i=1}^n \llbracket y^{(i)} w \cdot x^{(i)} \leq 0 \rrbracket$$

$$w^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$w^{(1)} \cdot x^{(2)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = -1 \longrightarrow -1 > 0, \text{hata yok}$$

$$w^{(1)} \cdot x^{(3)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \cdot \begin{bmatrix} -1 \\ 1.5 \end{bmatrix} = -0.5 \longrightarrow -0.5 < 0, \text{hata var, güncelle!}$$

$$w^{(2)} = w^{(1)} + y^{(3)} x^{(3)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} + 1 \begin{bmatrix} -1 \\ 1.5 \end{bmatrix} = \begin{bmatrix} -2 \\ 0.5 \end{bmatrix}$$